

Klasyfikacja Obiektów Astronomicznych

Gracjan Merk

12.06.2026

1 Wstęp

Celem projektu było zastosowanie metod uczenia maszynowego do klasyfikacji obiektów astronomicznych pochodzących z obserwacji nieba Sloan Digital Sky Survey (SDSS17). Zadaniem modelu było przypisanie każdego obiektu do trzech klas: GALAXY (galaktyka), STAR (gwiazda) lub QSO (kwazar). Przy wykonywaniu tego zadania model od razu też, sprawdzał jakie znaczenie mają poszczególne cechy wejściowe dla procesu klasyfikacji. Po tej analizie można było zauważyć, że redshift ma największy wpływ na proces klasyfikacji, sprawdzono skuteczność modelu przy braku tej cechy.

2 Opis zbioru danych

W projekcie wykorzystano zbiór danych SDSS17 zawierający 100 000 różnych obserwacji obiektów nocnego nieba. Każdy z nich był zestawem parametrów fotometrycznych i informacjami o jego położeniu na niebie.

Zbiór danych zawierał następujące klasy:

- Galaxy – 59 445 obiektów,
- Star – 21 594 obiekty,
- QSO – 18 961 obiektów.

Do budowy modeli wykorzystano osiem cech:

- alpha,
- delta,
- u,

- g,
- r
- i,
- z,
- redshift.

Pozostałe kolumny zostały pominięte, ponieważ były to głównie identyfikatory obserwacji i nie zawierały istotnych informacji wykorzystywanych do klasyfikacji.

3 Przygotowanie danych

Po wczytaniu danych program sprawdził czy występują jakieś brakujące wartości. Nie stwierdzono by takie braki w danych się znajdowały, w związku z czym nie było konieczności wykonywania dodatkowego czyszczenia zbioru.

Następnie wybrano cechy wejściowe oraz zakodowano etykiety klas przy użyciu klasy `LabelEncoder`. Pozwoliło to na zmianę etykiet tekstowych GALAXY, STAR i QSO na wartości liczbowe, które są wykorzystywane przez algorytmy uczenia maszynowego.

Dane podzielono na trzy zbiory:

- treningowy – 70% danych
- walidacyjny – 15% danych
- testowy – 15% danych

W celu zapewnienia porównywalności cech zastosowano standaryzację przy użyciu algorytmu `StandardScaler`

4 Zastosowane modele

W projekcie wykorzystaliśmy dwa modele uczenia maszynowego. Pierwszym z nich był Random Forest, który składa się z wielu drzew decyzyjnych, które dają swoje wyniki jako głosy, model zwraca wynik, który uzyska najwięcej głosów.

Drugim wykorzystanym modelem był Gradient Boosting. W przeciwieństwie do Random Forest kolejne drzewa uczone są sekwencyjnie, a każde następne drzewo stara się poprawić błędy popełnione przez poprzednie.


Celem zastosowania dwóch różnych modeli było porównanie ich skuteczności dla tego samego problemu klasyfikacyjnego.

5 Wyniki

Model Random Forest osiągnął dokładność klasyfikacyjną około 97,72%. Dla klasy GALAXY uzyskano wartość F1-score równa 0.98, dla klasy QSO wartość 0.94, a dla STAR wartość 1.00.

Model Gradient Boosting osiągnął dokładność około 97,5%. Otrzymane wyniki były bardzo zbliżone do wyników uzyskanych przez Random Forest, ale dla klasy QSO uzyskano nieco niższe wartości recall oraz F1-score.


Na podstawie przeprowadzonego porównania stwierdzono, że model Random Forest uzyskał lepsze wyniki (warto podkreślić, że Gradient Boosting nie odstawał aż tak bardzo) oraz został wybrany do dalszej analizy.



Rysunek 1: Porównanie skuteczności analizowanych modeli

Model	Accuracy
Random Forest	97.72%
Gradient Boosting	97.50%
Random Forest bez redshift	87.39%

Tabela 1: Porównanie dokładności modeli.




Rysunek 2: Macierze pomyłek dla analizowanych modeli

6 Analiza znaczenia cechy redshift


Dla modelu Random Forest przeprowadzona została analiza ważności cech. Otrzymane wyniki wykazały, że najważniejszą cechą jest parametr redshift, którego udział w procesie podejmowania decyzji był zdecydowanie większy niż pozostałych parametrów.

W celu sprawdzenia rzeczywistego wpływu tej cechy wykonano dodatkowy eksperyment. Ze zbioru danych usuneliśmy parametr redshift, a następnie ponownie wytrenowaliśmy model Random Forest.

Po usunięciu tej cechy dokładność klasyfikacji spadła z 97,72% do 87,39%. Największe pogorszenie wyników zaobserwowano dla klasy QSO oraz STAR. Oznacza to, że parametr redshift zawiera kluczowe informacje umożliwiające rozróżnianie poszczególnych typów obiektów astronomicznych.



(a) Ważność cech dla modelu Random Forest



(b) Wpływ cechy redshift na wynik


6.1 Permutation Feature Importance

By dokładniej zweryfikować znaczenie poszczególnych cech użyto metodę *Permutation Feature Importance*. W przeciwieństwie do standardowej analizy ważności cech wykorzystywanej przez Random Forest powyższa metoda polega na losowym mieszaniu wartości wybranej cechy i obserwacji spadku skuteczności modelu. Im większy spadek skuteczności, tym większe znaczenie danej cechy dla procesu klasyfikacji.

Otrzymane wyniki potwierdziły wcześniejsze obserwacje. Parametr *redshift* okazał się zdecydowanie najważniejszą cechą wykorzystywaną przez model. Po utracie informacji zawartej przez tą cechę skuteczność klasyfikacji ulegała sporemu pogorszeniu. Pozostałe cechy, takie jak *z*, *g*, *u* oraz *i*, miały zauważalnie mniejszy wpływ na działanie modelu.

Współrzędne *alpha* oraz *delta* charakteryzowały się niemal zerową ważnością. Oznacza to, że położenie obiektu na nocnym niebie nie dostarcza istotnych informacji pozwalających na rozróżnianie gwiazd, galaktyk i kwazarów.

Zgodność wyników uzyskanych metodą *Permutation Feature Importance* z wynikami klasycznej analizy ważności cech zwiększa wiarygodność przeprowadzonych obserwacji. Obie metody pokazały, że parametr *redshift* jest cechą dominującą, odpowiedzialną za skuteczną klasyfikację obiektów astronomicznych.



Rysunek 4

7 Wnioski

Przeprowadzono klasyfikacje obiektów astronomicznych należących do klas GALAXY, STAR i QSO. Zastosowano dwa modele uczenia maszynowego: Random Forest oraz Gradient Boosting. Oba modele osiągnęły bardzo wysoka skuteczność klasyfikacyjna przekraczającą 97%.

Najlepsze wyniki uzyskał Random Forest, który osiągnął dokładność 97,72%. Analiza ważności cech wykazała dominującą rolę parametru redshift. Dodatkowy eksperyment przeprowadzony bez tej cechy potwierdził jej znaczenie. Skuteczność klasyfikacji bez tej cechy spadła o ponad 10 punktów procentowych.